

1 Introdução

Diversos modelos de psicoterapia apresentam evidência de eficácia no tratamento de transtornos mentais. Uma parcela significativa dos pacientes, no entanto, não responde às intervenções, podendo até mesmo apresentar piora quando submetida a tratamento psicoterápico [4]. A variabilidade na taxa de resposta ao tratamento é parcialmente explicada pelo quadro clínico do paciente; ainda assim, observou-se que pessoas de uma mesma população clínica respondem de maneiras diferentes a um mesmo tratamento [6]. Especula-se que um atendimento personalizado a nível individual possa melhorar a taxa de resposta ao tratamento [9, 8].

A literatura aponta uma série de variáveis preditoras de desfecho clínico para pacientes em tratamento psicoterápico, o que permitiria a adaptação dos protocolos de intervenção de acordo com a expectativa de resposta [13, 1]. Não existe, porém, consenso acerca do valor preditivo de cada variável a nível individual e interações complexas entre diferentes preditores podem prejudicar a acurácia das previsões, podendo impactar propostas de personalização de tratamento negativamente [14].

Técnicas de inteligência artificial baseadas em aprendizagem de máquina apresentam a capacidade de integrar uma grande quantidade de dados, impondo poucas restrições ao comportamento das variáveis observadas e produzindo modelos flexíveis aplicáveis em diferentes contextos [5]. Em essência, a aprendizagem de máquina consiste no uso de métodos estatísticos e computacionais para identificar padrões de relacionamento subjacentes a um grande conjunto de dados, permitindo a construção de modelos classificatórios ou preditivos [11]. Estudos sobre a aplicação de modelos de aprendizagem de máquina na previsão do desfecho de tratamentos em saúde mental apresentam resultados promissores [5], o que possibilitaria maior assertividade na personalização de tratamentos psicoterápicos a nível individual. Embora promissores, os modelos de aprendizagem de máquina apresentam uma série de limitações e sua aplicação em contextos de saúde deve ser criteriosamente avaliada. Para tanto, a Organização Mundial da Saúde documentou uma série de considerações sobre o uso dessa tecnologia nos cuidados em saúde, incluindo temas como validação analítica do modelo, métricas de performance e comparação [10].

Este trabalho tem por objetivo identificar e discutir as possíveis aplicações e limitações do uso de modelos baseados em aprendizagem de máquina na prática da psicologia clínica. Busca-se também ilustrar o uso da aprendizagem de máquina no auxílio à tomada de decisões para o planejamento de intervenções psicoterápicas. Utilizando um conjunto de dados de uma intervenção digital em psicologia positiva para depressão [3], pretende-se construir modelos de regressão linear, clustering, support vector machine, árvores de decisão e redes neurais, avaliando o desempenho e discutindo a adequação de cada técnica ao contexto da psicologia clínica.

2 Desenvolvimento

Texto do desenvolvimento.

2.1 O que é aprendizagem de máquina?

Aprendizagem de máquina é a área da ciência da computação que tem como objetivo geral o desenvolvimento de programas de computador capazes de aprender a realizar uma tarefa sem serem explicitamente programados [2, 15]. Neste contexto, aprendizagem refere-se a aplicação de procedimentos estatísticos e computacionais sobre um conjunto de informações empíricas, buscando alcançar melhorias de desempenho em uma determinada tarefa [15]. Aprender trata-se, portanto, de ajustar os parâmetros de um modelo estatístico e computacional aos dados observados de modo a maximizar o desempenho na tarefa em questão [2]. Programas de computador baseados em aprendizagem de máquina são capazes de identificar padrões de interação complexos entre variáveis em conjuntos de dados com alta dimensionalidade para realizar tarefas de classificação, regressão, agrupamento e outras [15].

Considere, por exemplo, um estudo observacional hipotético que investiga a relação entre características de personalidade e o nível de satisfação profissional entre psicólogos. O estudo baseia-se no modelo dos cinco grandes fatores da personalidade [7] e usa o instrumento da Bateria Fatorial da Personalidade para coleta de dados, registrando as pontuações obtidas nas escalas de neuroticismo, extroversão, socialização, realização e abertura [12]. Além disso, os participantes do estudo reportam o próprio nível de satisfação profissional em uma escala que contém os seguintes valores: baixo, médio e alto. O conjunto de dados coletados é como apresentado na tabela 1.

neuroticismo	extroversão	socialização	realização	abertura	satisfação
1	1	2	4	5	alto
1	1	2	4	5	baixo
1	1	2	4	5	médio
1	1	2	4	5	médio

Table 1: Exemplo de dados coletados no estudo hipotético.

É possível utilizar esse conjunto de dados para construir um modelo de aprendizagem de máquina preditivo. Um algoritmo processa o conjunto de dados, identificando os padrões de interação existentes entre as variáveis preditoras (características de personalidade) e o desfecho de interesse (nível de satisfação profissional). O conhecimento adquirido durante o processamento dos dados é codificado nos parâmetros de um modelo de aprendizagem de máquina. O modelo pode então ser utilizado para fazer previsões sobre o nível de satisfação profissional de um indivíduo qualquer a partir de suas características de personalidade.

2.2 Quais os tipos de técnicas de machine learning?

As diferentes técnicas de aprendizagem de máquina podem ser classificadas de acordo com a estratégia adotada durante o processo de aprendizagem. As principais categorias são: aprendizagem supervisionada, aprendizagem não supervisionada e aprendizagem por reforço [2].

2.2.1 Supervisionada

Na aprendizagem supervisionada, a aplicação é exposta a um conjunto de dados que contém informações sobre o desfecho para cada uma das observações. A informação sobre o desfecho pode ser um conjunto de variáveis ou uma única variável; em ambos os casos as variáveis podem representar quantidades ou categorias. O fato de a aplicação ter acesso às informações de desfecho, geralmente providas por um agente externo (um pesquisador que registrou os desfechos manualmente), confere o caráter de supervisão à este processo. Técnicas de aprendizagem de máquina para regressão e classificação (support vector machines, árvores de decisão, redes neurais) pertencem a esta categoria.

2.2.2 Não supervisionada

Na aprendizagem não supervisionada, o conjunto de dados analisado não contém informações sobre o desfecho para as observações; perde-se assim a característica de supervisão. Espera-se que a aplicação identifique, de maneira autônoma, os padrões de relacionamento existentes entre as variáveis do conjunto de dados. Técnicas de aprendizagem de máquina populares para tarefas de agrupamento e redução de dimensionalidade (k-means clustering, PCA, TSNE) pertencem a esta categoria.

2.2.3 Por reforço

Na aprendizagem por reforço, as aplicações adquirem conhecimento a respeito da tarefa ao longo do tempo por meio da obtenção de feedback sobre seu desempenho.

2.3 A construção de uma aplicação de machine learning

2.3.1 Análise descritiva

2.3.2 Pré-processamento

Na etapa de pré-processamento, busca-se preparar o conjunto de dados de treinamento, colocando-no em um estado adequado à técnica de aprendizagem de máquina que se pretende utilizar. Tratamentos comumente realizados na etapa de pré-processamento são: seleção de características, transformações, imputações e balanceamento de classes.

A seleção de características consiste em eliminar do conjunto de dados as variáveis que tenham pouca contribuição para a aprendizagem da tarefa. Em

um conjunto de dados onde todas as observações são de pessoas brasileiras, a variável de nacionalidade não contribui para a explicação do desfecho que se busca prever, portanto pode ser removida.

Transformações são aplicadas de acordo com os requisitos da técnica de aprendizagem de máquina em uso. Por exemplo, algumas técnicas de aprendizagem de máquina são suscetíveis à influência de variáveis com escala muito superior às demais; nesses casos é comum transformação das variáveis para uma escala padronizada (medida em desvios padrão a partir da média).

2.3.3 Treinamento do modelo

2.3.4 Validação do modelo

2.4 Parte 2

Texto da parte 2.

3 Conclusão

Texto da conclusão.

References

- [1] Margaret S. Andover et al. “Moderators of treatment response to an intervention for nonsuicidal self-injury in young adults.” In: *Journal of Consulting and Clinical Psychology* 88.11 (Nov. 2020), pp. 1032–1038. ISSN: 0022-006X. DOI: 10.1037/ccp0000603. URL: <http://dx.doi.org/10.1037/ccp0000603>.
- [2] Qifang Bi et al. “What is Machine Learning? A Primer for the Epidemiologist”. In: *American Journal of Epidemiology* (Oct. 2019). ISSN: 1476-6256. DOI: 10.1093/aje/kwz189. URL: <http://dx.doi.org/10.1093/aje/kwz189>.
- [3] Amanda C. Collins et al. “Predicting individual response to a web-based positive psychology intervention: a machine learning approach”. In: *The Journal of Positive Psychology* 19.4 (Sept. 2023), pp. 675–685. ISSN: 1743-9779. DOI: 10.1080/17439760.2023.2254743. URL: <http://dx.doi.org/10.1080/17439760.2023.2254743>.
- [4] Pim Cuijpers et al. “The effects of psychotherapies for depression on response, remission, reliable change, and deterioration: A meta-analysis”. In: *Acta Psychiatrica Scandinavica* 144.3 (July 2021), pp. 288–299. ISSN: 1600-0447. DOI: 10.1111/acps.13335. URL: <http://dx.doi.org/10.1111/acps.13335>.
- [5] Dominic B. Dwyer, Peter Falkai, and Nikolaos Koutsouleris. “Machine Learning Approaches for Clinical Psychology and Psychiatry”. In: *Annual Review of Clinical Psychology* 14.1 (May 2018), pp. 91–118. ISSN: 1548-5951. DOI: 10.1146/annurev-clinpsy-032816-045037. URL: <http://dx.doi.org/10.1146/annurev-clinpsy-032816-045037>.
- [6] Stefan G. Hofmann et al. “The Efficacy of Cognitive Behavioral Therapy: A Review of Meta-analyses”. In: *Cognitive Therapy and Research* 36.5 (July 2012), pp. 427–440. ISSN: 1573-2819. DOI: 10.1007/s10608-012-9476-1. URL: <http://dx.doi.org/10.1007/s10608-012-9476-1>.
- [7] Cláudio S Hutz. *Avaliação Psicológica da Inteligência e da Personalidade*. Artmed, Apr. 2018.
- [8] John C. Norcross and Michael J. Lambert. “Psychotherapy relationships that work III.” In: *Psychotherapy* 55.4 (Dec. 2018), pp. 303–315. ISSN: 0033-3204. DOI: 10.1037/pst0000193. URL: <http://dx.doi.org/10.1037/pst0000193>.
- [9] John C. Norcross and Bruce E. Wampold. “What works for whom: Tailoring psychotherapy to the person”. In: *Journal of Clinical Psychology* 67.2 (Nov. 2010), pp. 127–132. ISSN: 1097-4679. DOI: 10.1002/jclp.20764. URL: <http://dx.doi.org/10.1002/jclp.20764>.
- [10] World Health Organization. *Regulatory considerations on artificial intelligence for health*. World Health Organization, 2023, xiv, 61 p.

- [11] Jan A. Roth et al. “Introduction to Machine Learning in Digital Healthcare Epidemiology”. In: *Infection Control and Hospital Epidemiology* 39.12 (Nov. 2018), pp. 1457–1462. ISSN: 1559-6834. DOI: 10.1017/ice.2018.265. URL: <http://dx.doi.org/10.1017/ice.2018.265>.
- [12] Carlos H Sancineto. *Bateria Fatorial da Personalidade - BFP: manual técnico*. Casa do Psicólogo, 2015.
- [13] Stephen F. Smagula et al. “Moderators of Response to Cognitive Behavior Therapy for Major Depression in Patients With Heart Failure”. In: *Psychosomatic Medicine* 81.6 (May 2019), pp. 506–512. ISSN: 0033-3174. DOI: 10.1097/psy.0000000000000712. URL: <http://dx.doi.org/10.1097/PSY.0000000000000712>.
- [14] Friedrich-Samuel Taubitz, Björn Büdenbender, and Georg W. Alpers. “What the future holds: Machine learning to predict success in psychotherapy”. In: *Behaviour Research and Therapy* 156 (Sept. 2022), p. 104116. ISSN: 0005-7967. DOI: 10.1016/j.brat.2022.104116. URL: <http://dx.doi.org/10.1016/j.brat.2022.104116>.
- [15] Oliver Theobald. *Machine learning for absolute beginners*. Scatterplot Press, Jan. 2021.